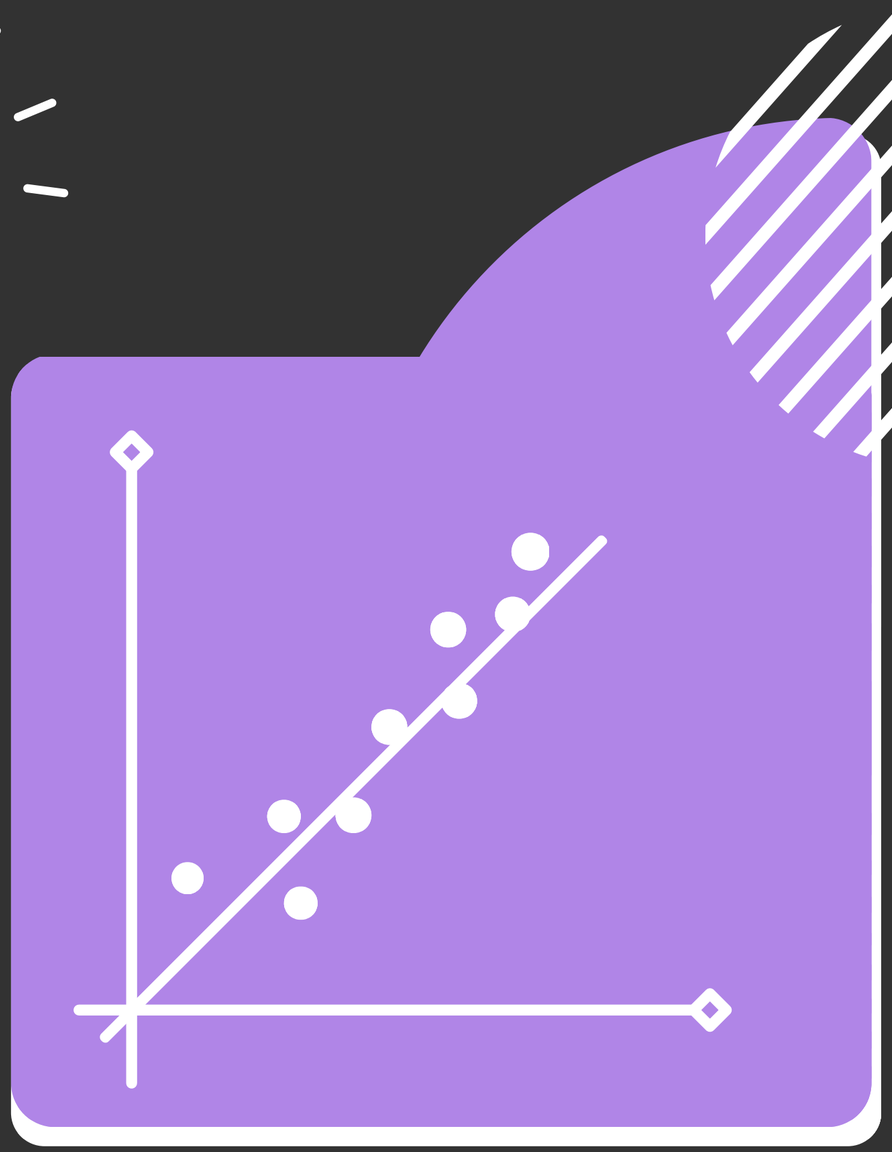
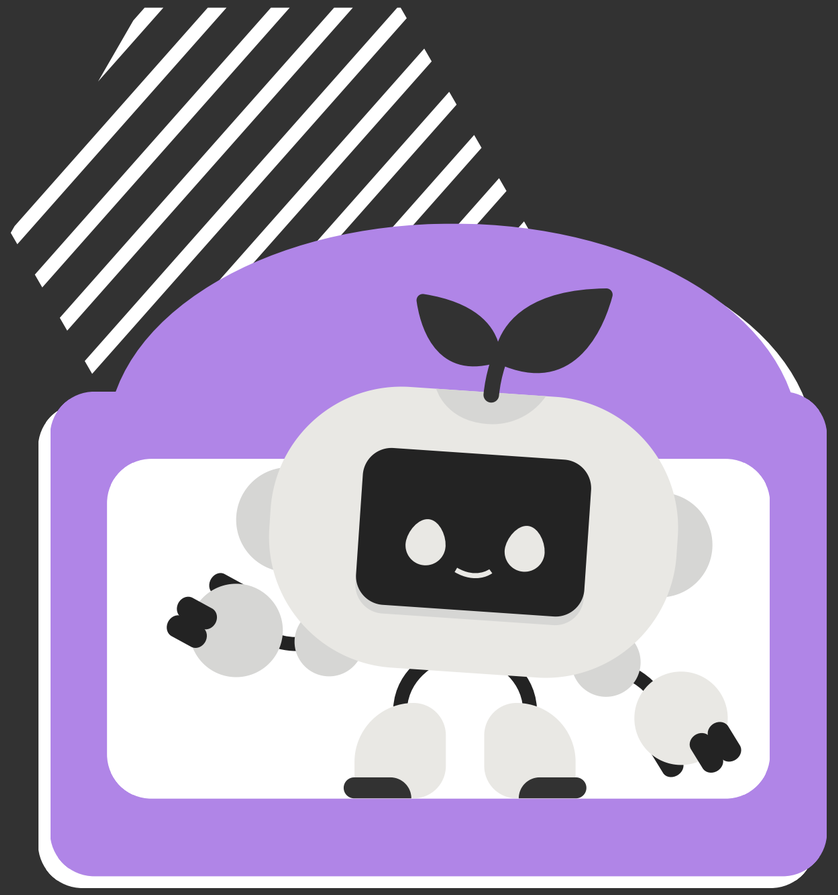
ANALISIS DATA INDEKS KEBAHAGIAAN PENDUDUK DENGAN MODEL REGRESI LINEAR



Kelompok 3

KONTEKS DAN PENDAHULUAN

Kebahagian penduduk suatu negara merupakan suatu indikator yang menggambarkan tingkat kesejahteraan dan kualitas hidup penduduk. Adanya perbedaan tingkat kebahagiaan antarnegara menjadi hal yang menarik untuk dianalisis, khususnya dalam mengidentifikasi faktor-faktor yang memiliki **pengaruh** dengan tingkat kebahagiaan tersebut. Oleh karena itu, penelitian pada dataset ini menggunakan metode regresi linear untuk menganalisis pengaruh antara indikator ekonomi dan sosial dengan Happiness Score. Sedangkan, metode korelasi digunakan untuk menganalisis **hubungan** antara indikator-indikator dengan Happiness Score.

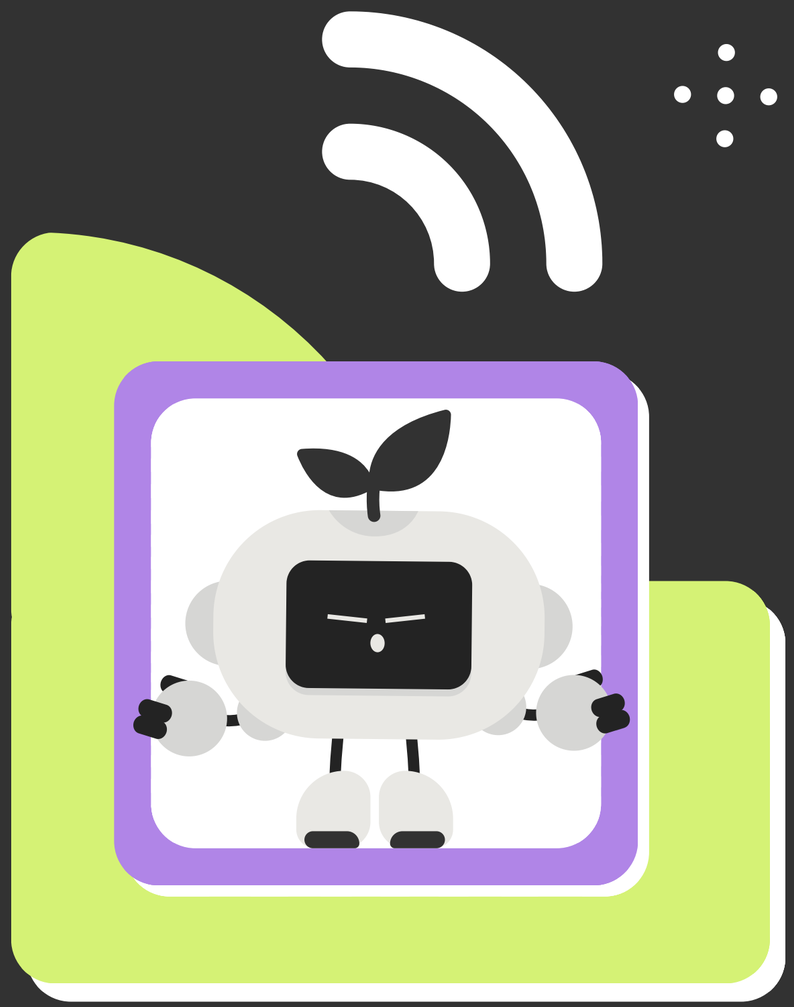


PREVIEW DATA

	Overall rank	Country or region	Score	GDP per capita	Social support	Healthy life expectancy	Freedom to make life choices	Generosity	Perceptions of corruption
0	1	Finland	7.632	1.305	1.592	0.874	0.681	0.202	0.393
1	2	Norway	7.594	1.456	1.582	0.861	0.686	0.286	0.340
2	3	Denmark	7.555	1.351	1.590	0.868	0.683	0.284	0.408
3	4	Iceland	7.495	1.343	1.644	0.914	0.677	0.353	0.138
4	5	Switzerland	7.487	1.420	1.549	0.927	0.660	0.256	0.357
5	6	Netherlands	7.441	1.361	1.488	0.878	0.638	0.333	0.295
6	7	Canada	7.328	1.330	1.532	0.896	0.653	0.321	0.291
7	8	New Zealand	7.324	1.268	1.601	0.876	0.669	0.365	0.389
8	9	Sweden	7.314	1.355	1.501	0.913	0.659	0.285	0.383
9	10	Australia	7.272	1.340	1.573	0.910	0.647	0.361	0.302

Ukuran data : 156 rows x 9 columns

Dataset by Sougata Pramanick(2022), Happiness Index 2018-2019:
https://www.kaggle.com/datasets/sougatapramanick/happiness-index-2018-2019



VARIABEL DATA

- **Country or Region** (Categorical): Negara atau wilayah objek pengamatan.
- **Score** (Continuous): Tingkat kebahagiaan penduduk suatu wilayah.
- **GDP per capita** (Continuous): Sebagai acuan gaji rata-rata penduduk.
- **Social support** (Continuous): Tingkat dukungan sosial yang dirasakan masyarakat.
- **Healthy Life Expectancy** (Continuous): Harapan hidup sehat masyarakat
- **Freedom to make life choices** (Continuous): tingkat kebebasan individu dalam menentukan pilihan hidupnya.
- **Generosity** (Continuous): Tingkat kedermawanan masyarakat (perilaku memberi atau berdonasi).
- **Perceptions of Corruption** (Continuous): Persepsi masyarakat terhadap tingkat korupsi suatu negara.

VARIABEL X DAN Y

Y = Happiness Score

X1 = GDP Per Capita
X2 = Healthy Life Expectancy
X3 = Social Support
X4 = Perception of Corruptions

ALASAN MEMILIH VARIABEL X DAN Y

Happiness Score dipilih sebagai variabel Y sebagai elemen penilitian yang ingin diprediksi nilainya berdasarkan indikator-indikator variabel X nya.

- GDP per capita dipilih untuk merepresentasikan kondisi ekonomi.
- Healthy Life Expectancy dipilih untuk merpresentasikan faktor kesehatan.
- Social support dipilih untuk melihat pengaruh faktor psikologis.
- Perception of Corruption dipilih untuk melihat tingkat kepercayaan masyarakat terhadap pemerintah.

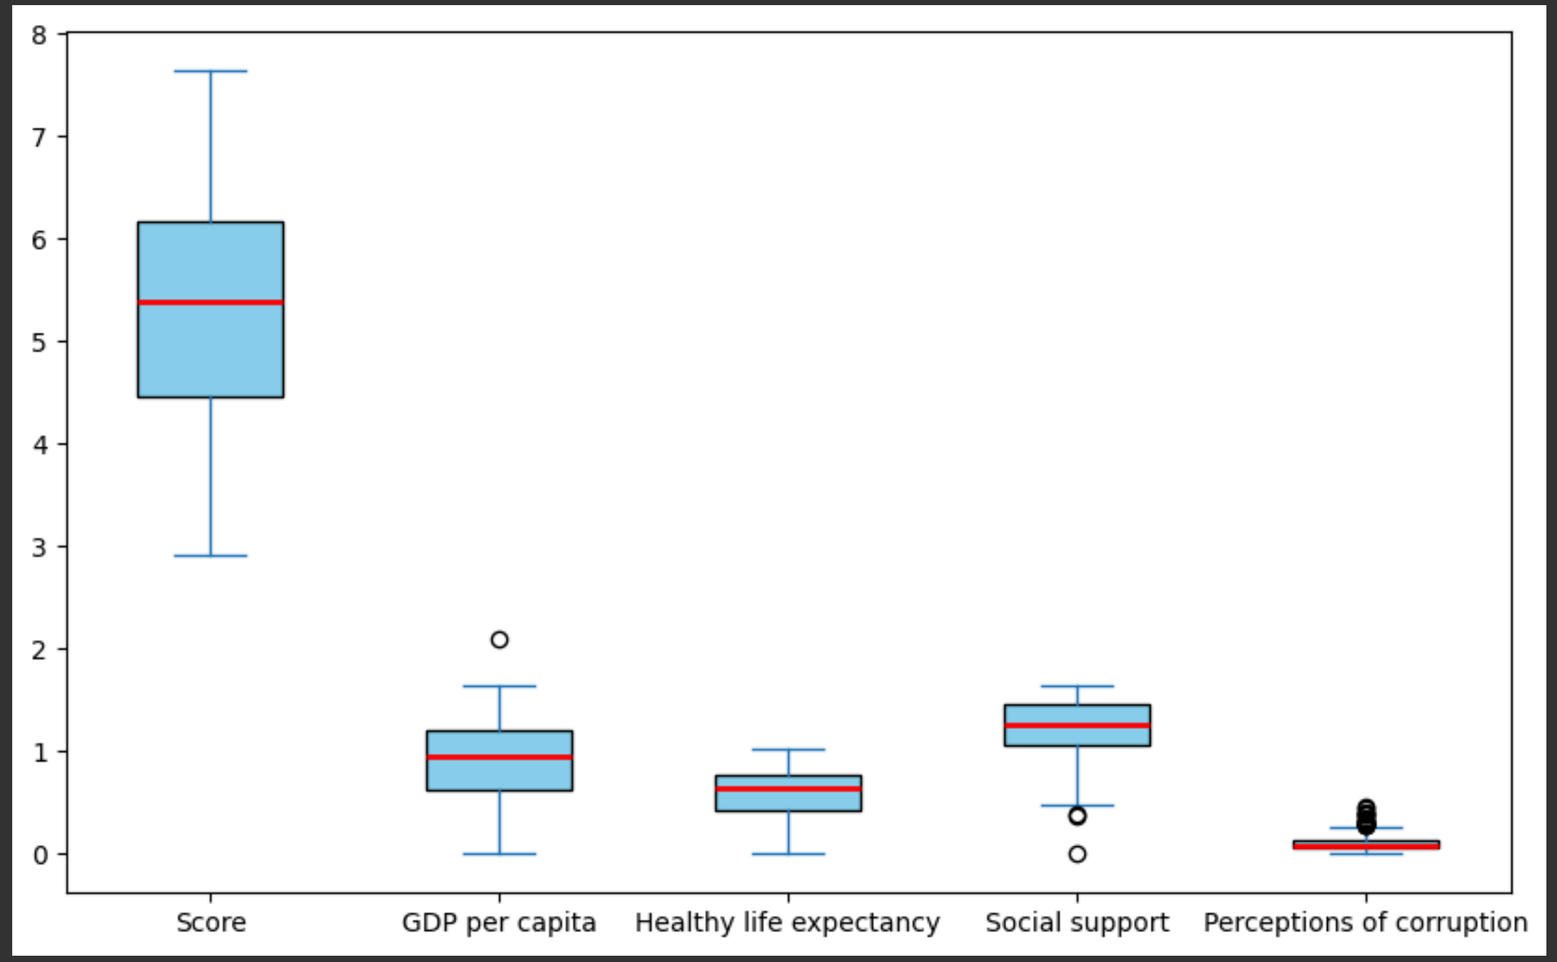
STATISTIKA DESKRIPTIF

	Score	GDP per capita	Healthy life expectancy	Social support	Perceptions of corruption
count	156.000000	156.000000	156.000000	156.000000	156.000000
mean	5.375917	0.891449	0.597346	1.213237	0.112449
std	1.119506	0.391921	0.247579	0.302372	0.096343
min	2.905000	0.000000	0.000000	0.000000	0.000000
25%	4.453750	0.616250	0.422250	1.066750	0.051000
50%	5.378000	0.949500	0.644000	1.255000	0.082000
75%	6.168500	1.197750	0.777250	1.463000	0.139000
max	7.632000	2.096000	1.030000	1.644000	0.457000

Hasil statistika deskriptif memberikan gambaran mengenai nilai pemusatan dan penyebaran data sehingga karakteristik setiap variabel dapat dipahami sebelum dilakukan analisis regresi linear.

STATISTIKA DESKRIPTIF

Boxplot Variabel Numerik



Berdasarkan diagram boxplot untuk masing-masing variabel penelitian di samping, variabel *Perceptions of corruption* memiliki outiler yang terbanyak dan menumpuk di atas penyebaran data. Maka dapat diasumsikan bentuknya menceng ke kanan.

ANALISIS KORELASI SINGKAT

```
corr_1 = df["GDP per capita"].corr(df["Score"])
print("GDP per capita :", corr_1)

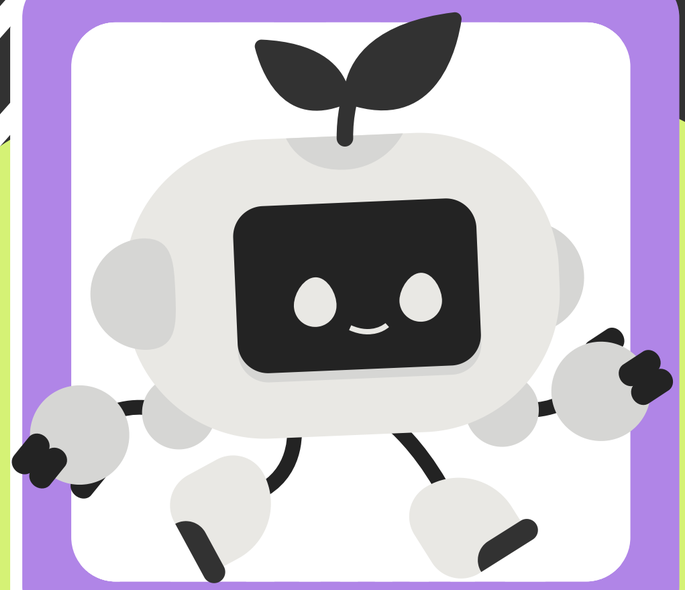
corr_2 = df["Healthy life expectancy"].corr(df["Score"])
print("Healthy life expectancy :", corr_2)

corr_3 = df["Social support"].corr(df["Score"])
print("Social support :", corr_3)

corr_4 = df["Perceptions of corruption"].corr(df["Score"])
print("Perceptions of corruption :", corr_4)
```

```
GDP per capita : 0.8021239467301907
Healthy life expectancy : 0.7758136033302464
Social support : 0.7457601649725755
Perceptions of corruption : 0.40840527966777723
```

Variabel GDP per capita memiliki hubungan korelasi yang paling kuat dengan variabel Y, yaitu sebesar 0,80



ANALISIS REGRESI SEDERHANA

TRAINING & TESTING

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

X = df_reg[['GDP per capita']]
y = df_reg['Score']
X_train, X_test,
y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=42)

model = LinearRegression()
model.fit(X_train, y_train)
```

Dataset	Percentage	Observations
Training	75%	117
Testing	25%	39
Total	100%	156

Sebanyak 75% data dialokasikan ke training dan 25% dialokasikan ke testing.
Training digunakan untuk mengembangkan model regresi linear dan mengestimasi koefisien-koefisiennya.
Testing digunakan untuk mengevaluasi kinerja prediksi model dengan menggunakan observasi yang belum pernah dilihat sebelumnya.

OUTPUT MODEL REGRESI

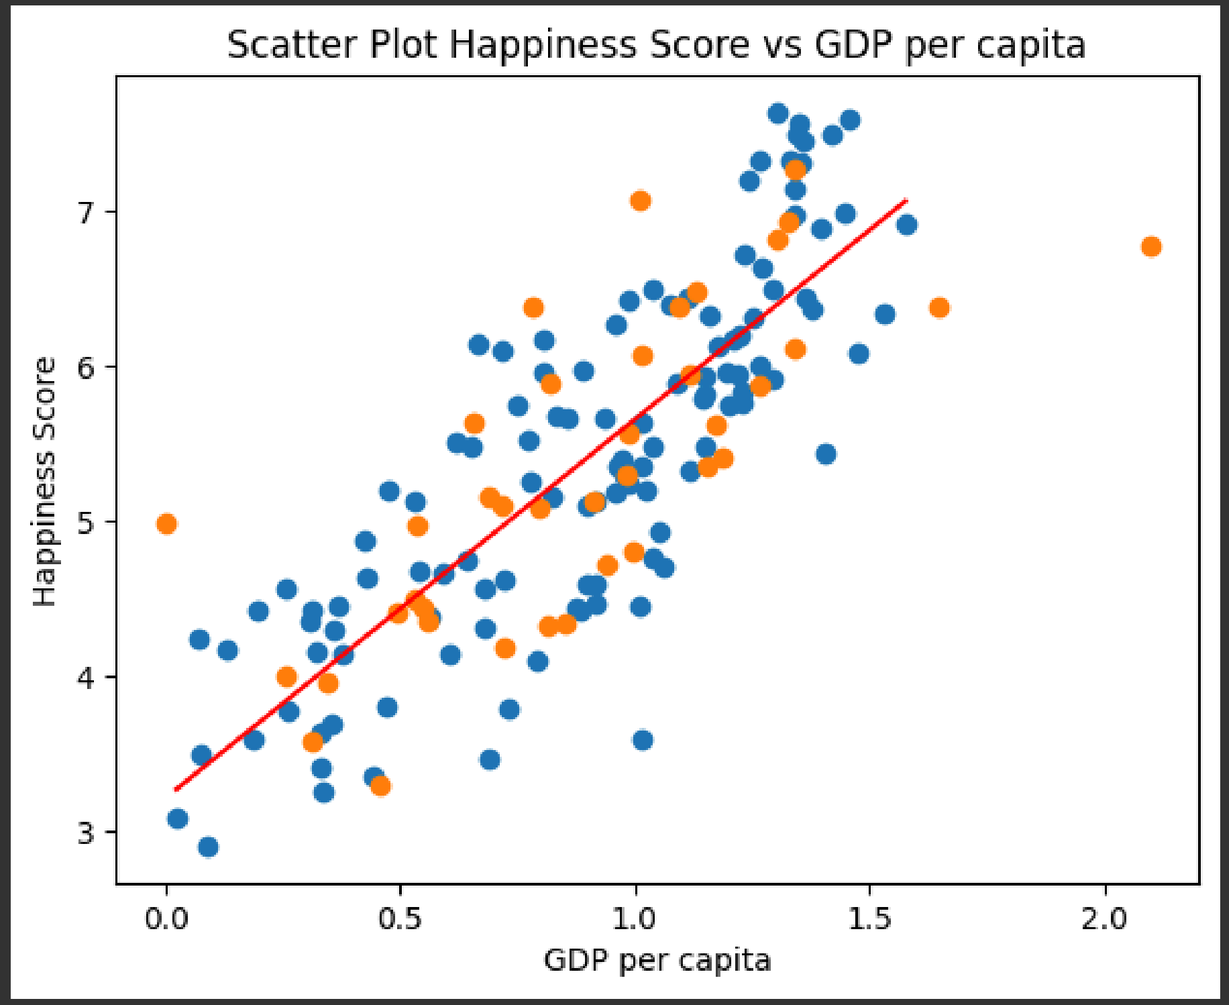
Persamaan Model Regresi Linear Sederhana :

$$\hat{Y} = 3.211 + (2.441)\ X1$$

Y = Happiness Score Prediction
X1 = GDP Per Capita

Nilai koefisien menunjukkan angka yang positif, ini artinya variabel GDP per capita memiliki hubungan yang positif atau searah dengan skor kebahagiaan.

SCATTER PLOT



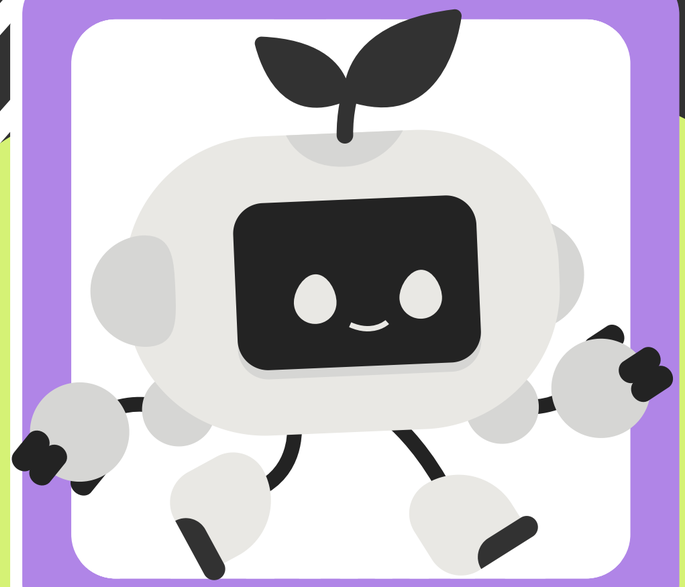
Sebaran plot untuk nilai aktual X membentuk pola naik yang lumayan rapat dan mengikuti garis lurus prediksi. Akan tetapi ada beberapa nilai observasi yang menyimpang jauh dari nilai prediksi dibuktikan dengan letak titiknya yang jauh dari garis prediksi.

MAE, RMSE, DAN R SQAURE

```
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
pred_test = model.predict(X_test)
mae = mean_absolute_error(y_test,pred_test)
rmse = np.sqrt(mean_squared_error(y_test,pred_test))
r2 = r2_score(y_test,pred_test)
print("mae :", mae)
print("rmse :", rmse)
print("r2 :", r2)
```

```
mae : 0.5621155443388103
rmse : 0.7077425337159496
r2 : 0.5002148008935017
```

Nilai MAE pada model tersebut sebesar 0,56 dan RMSE sebesar 0,7 sehingga dapat dikatakan errornya relatif sedang menuju tinggi. Sedangkan, nilai R square untuk model ini adalah 0,5 yang dimana angka ini berada di tengah-tengah. Ini menunjukkan 50% dari variasi nilai happiness score dapat dijelaskan oleh GDP per capita dan sisanya dijelaskan oleh variabel lainnya.



ANALISIS REGRESI MULTILINEAR

TRAINING & TESTING

```python
#Menentukan Variabel X dan Y
kolom_x = ['GDP per capita','Social support',
           'Healthy life expectancy',
           'Perceptions of corruption',
]
X = df[kolom_x]
y = df['Score']
```

```python
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split

#Membuat dan Melatih Model Regresi Linear Berganda
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=2026)
model = LinearRegression()
model.fit(X_train, y_train)

# Melakukan prediksi
y_pred = model.predict(X_test)
```

Variabel-variabel yang digunakan sebagai prediktor antara lain GDP per capita, Social Support, Healthy Life Expectancy, serta Perceptions of corruption. Sedangkan variabel targetnya adalah Happines Score. Data yang digunakan untuk training sebesar 80% sedangkan untuk testing sebesar 20%

OUTPUT DAN MODEL REGRESI

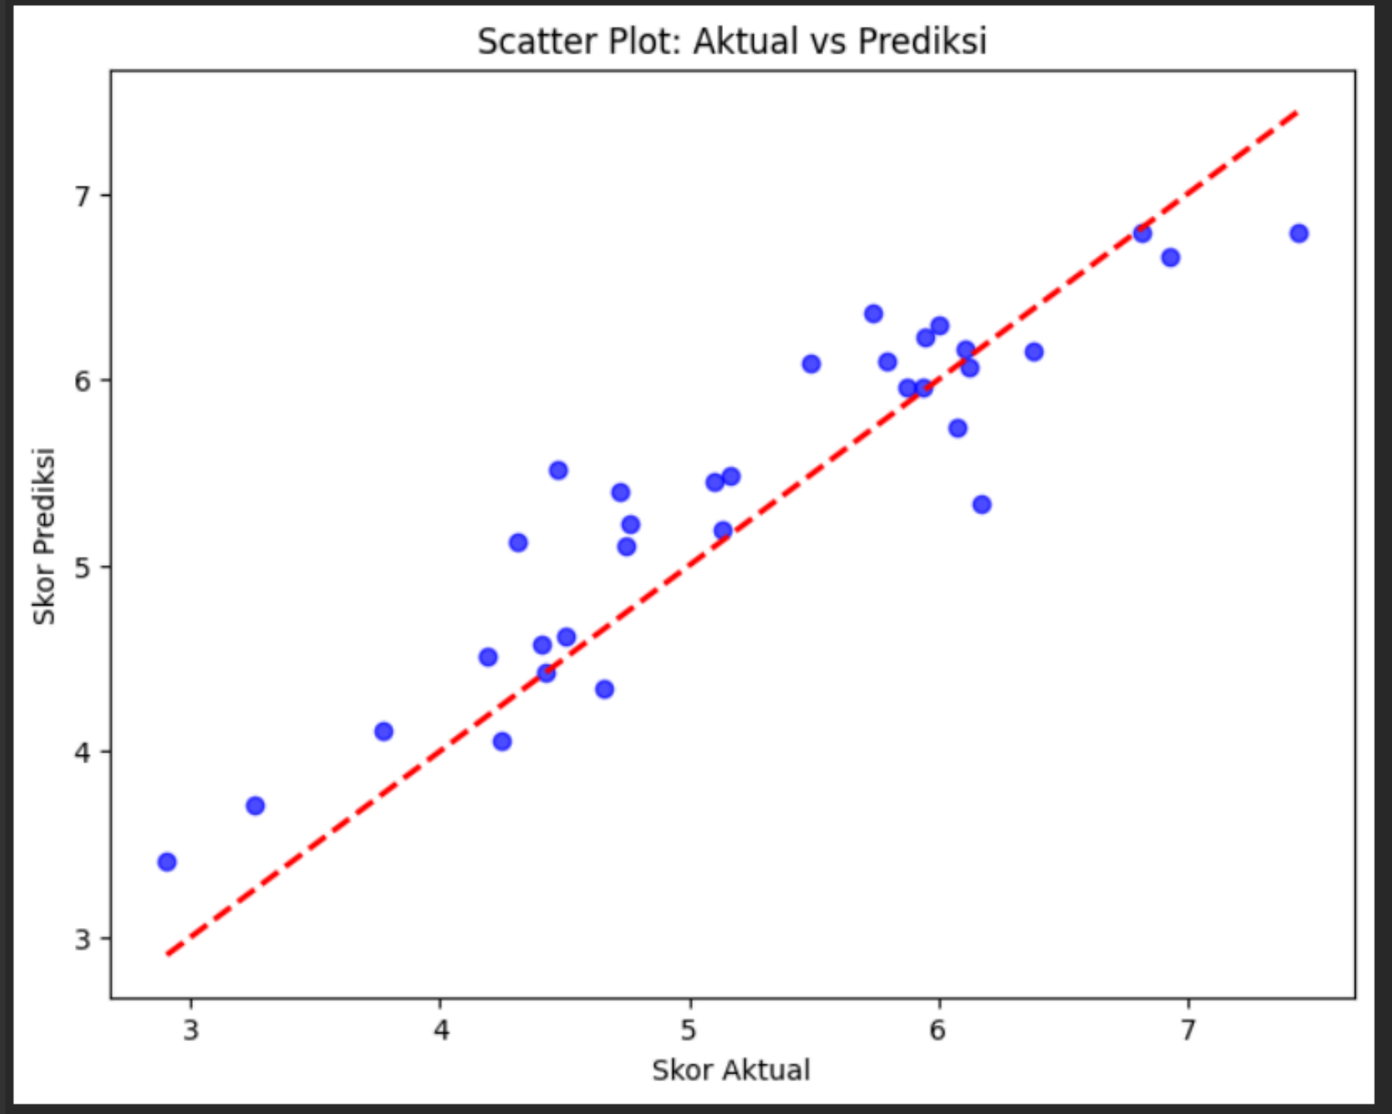
Persamaan Model Regresi Linear Berganda :

$$\hat{Y} = 2.51 + 1.01\,X1 + 1.29\,X2 + 0.81\,X3 + 1.75\,X4$$

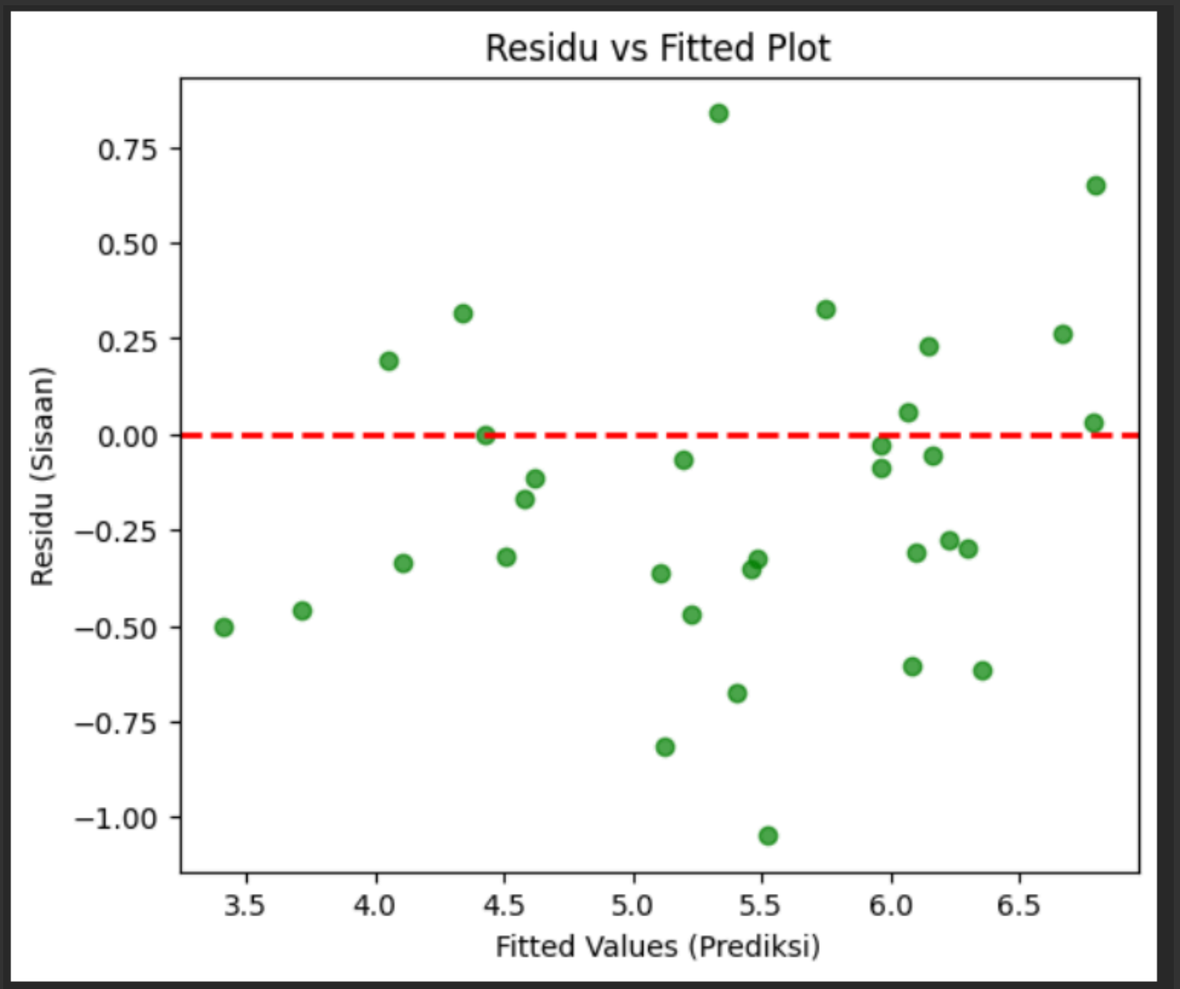
Y = Happiness Score Prediction
X1 = GDP Per Capita
X2 = Social Support
X3 = Healthy Life Expectancy
X4 = Perceptions of Corruption

SCATTER PLOT

Hasil scatter plot menunjukkan bahwa sebagian besar titik-titik data mengelompok rapat dengan garis ideal, menandakan model memiliki korelasi positif yang kuat. Akan tetapi, pada beberapa data point, model melakukan *overpredict* dan *underpredict*.



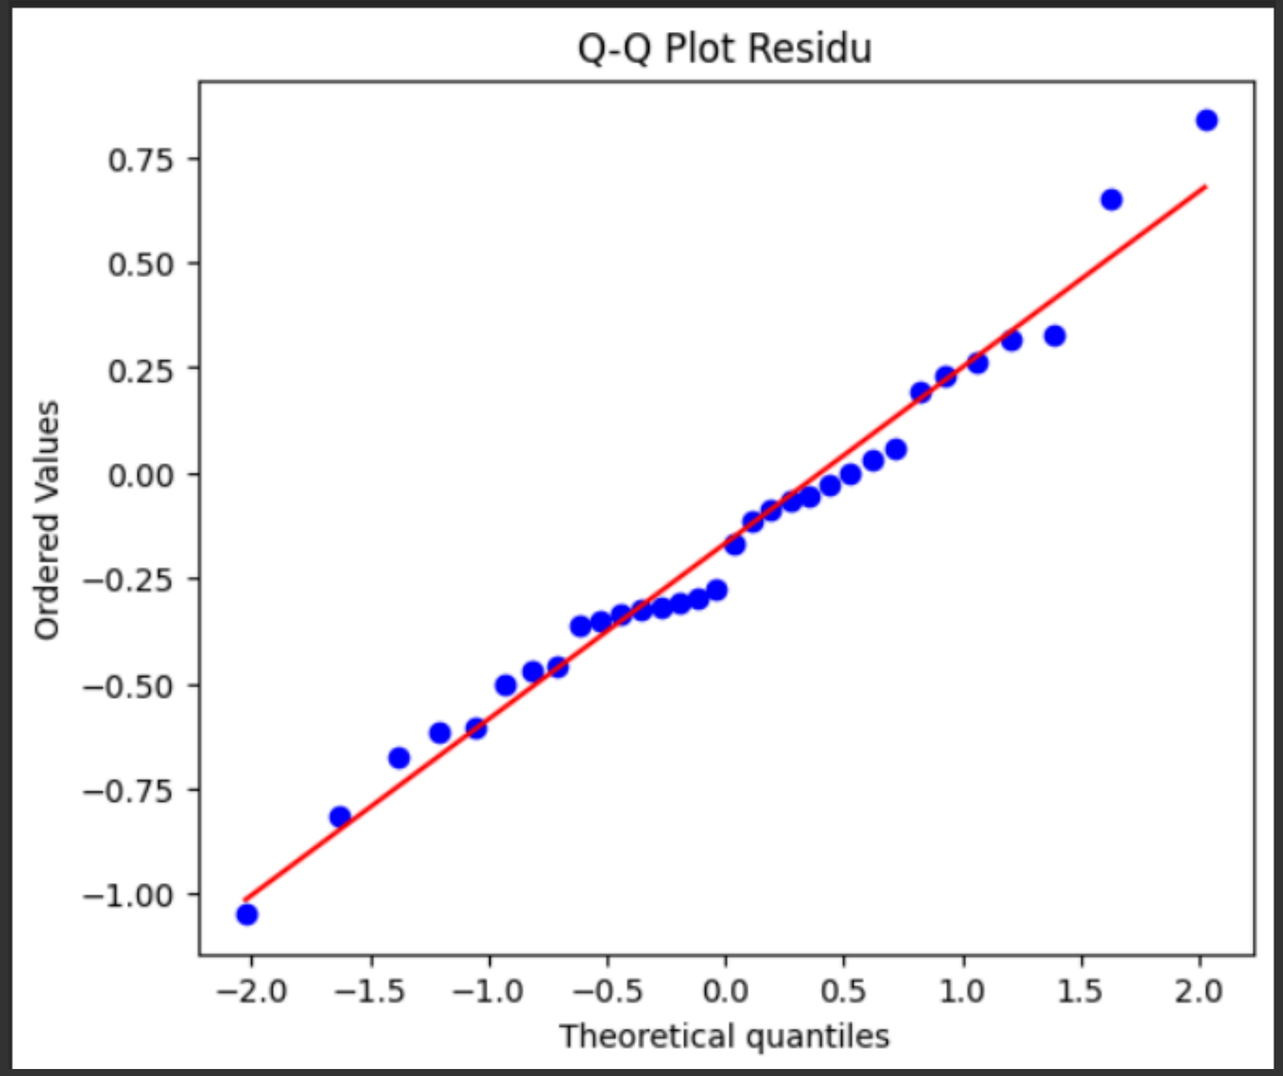
RESIDUAL VS FITTED



Residual vs Fitted menunjukkan bahwa residual pada umumnya tersebar di sekitar garis acuan nol tanpa pola sistematis yang jelas. Tetapi, terdapat beberapa observasi dengan nilai residual yang relatif besar. Secara keseluruhan, plot tersebut menunjukkan bahwa model regresi linear cukup akurat, meskipun masih terdapat beberapa kesalahan prediksi.

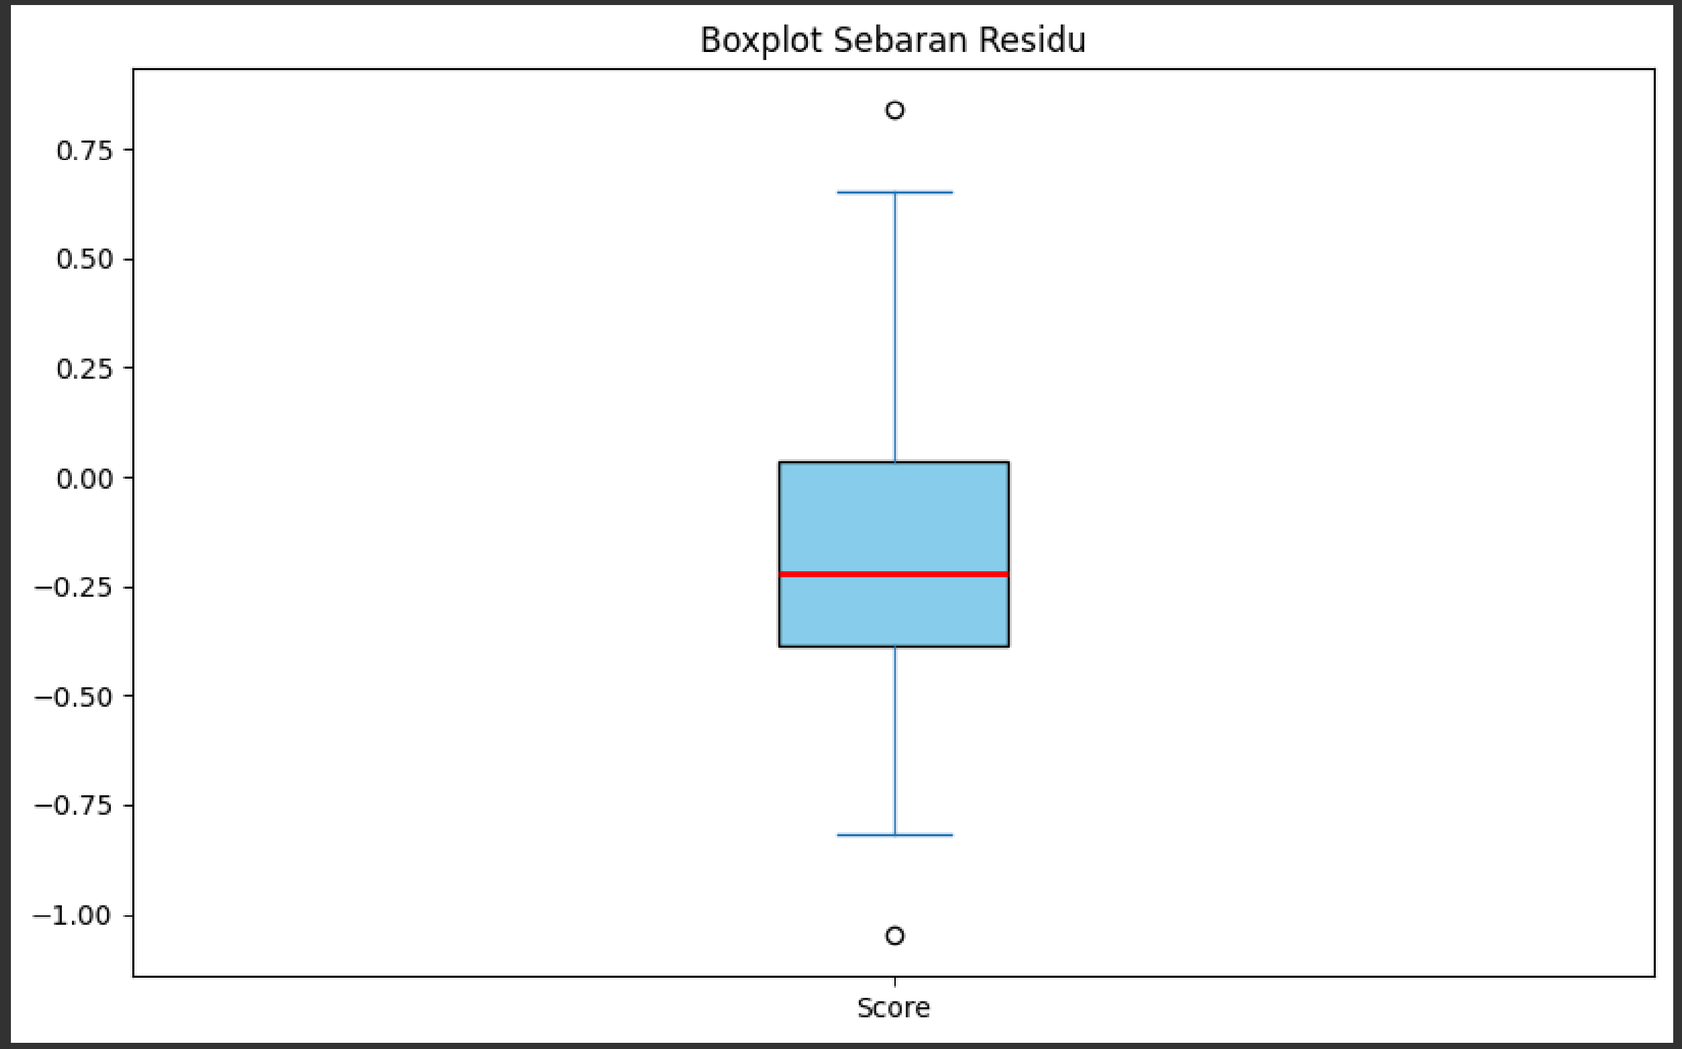
Berdasarkan pola pada plot di samping, titik-titiknya menyebar cukup abstrak dan tidak membentuk suatu pola seperti corong. Hal ini menunjukkan bahwa tidak terjadinya heterokedastisitas yang menandakan adanya perubahan ragam.

Q-Q PLOT



Q-Q Plot menunjukkan bahwa sebagian besar observasi residual mengikuti garis ideal dengan cukup rapat, yang mengisyaratkan bahwa residual tersebut **berdistribusi mendekati normal.** Namun, terdapat beberapa penyimpangan pada bagian ujung atas, yang menandakan adanya residual positif yang relatif besar. Secara keseluruhan, residual tersebut cukup memenuhi asumsi normalitas, meskipun terdapat penyimpangan-penyimpangan kecil.

RESIDU OUTLIER



Terdapat dua outlier pada bagian atas dan bawah data, dengan median di bawah nol yaitu -0,25

MAE, RMSE, DAN R SQAURE

```python
#Menghitung Evaluasi Model (MAE, RMSE, R^2)
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)

print('\n--- EVALUASI MODEL ---')
print(f'MAE  : {mae}')
print(f'RMSE : {rmse}')
print(f'R^2  : {r2}')
```

```
--- EVALUASI MODEL ---
MAE  : 0.34953349668452904
RMSE : 0.4345229155206138
R^2  : 0.8285505013668428
```

Nilai MAE pada model tersebut sebesar 0,34 dan RMSE sebesar 0,43 jika diukur dengan rata-rata variabel y nya, sehingga dapat dikatakan errornya relatif rendah. Sedangkan, nilai R square untuk model ini adalah 0,8 yang dimana angka ini mendekati nilai satu. Ini menunjukkan 80% dari variasi nilai *happiness score* terjelaskan oleh setiap variabel x dalam *multilinear regression*

TABEL PERBANDINGAN MAE, RMSE, DAN R SQUARE

	Simple Linear Regression	Multiple Linear Regression
MAE	0,56	0,34
RMSE	0,7	0,43
R^2	0,5	0,8

Nilai MAE dan RMSE pada *Multiple Linear Regression* lebih kecil dibandingkan *Simple Linear Regression*, menunjukkan bahwa kesalahan prediksi lebih kecil pada *Multiple* dibandingkan *Single*. *Multiple* juga dapat menjelaskan, melalui variabel indepedennya 80% variabel dependen dibandingkan *Single* 50%. Hal ini menunjukkan bahwa model *Multiple Linear Regression* memiliki kemampuan penjelasan yang lebih tinggi dibandingkan model regresi linear sederhana.

MULTIKOLINEARITAS



Jika dilihat dari Correlation HeatMap untuk masing-masing variabel prediktor, beberapa variabel memiliki nilai korelasi yang cukup tinggi, artinya kedua variabel prediktor tersebut memiliki hubungan tertentu dan perlu dicurigakan adanya multikolinearitas.

VIF SEDERHANA

```python
#Multikolinearitas (VIF Sederhana)
from statsmodels.stats.outliers_influence import variance_inflation_factor
import statsmodels.api as sm

X_sm = sm.add_constant(X_train)
print('\n--- NILAI VIF (Multikolinearitas) ---')
for i in range(X_sm.shape[1]):
  vif = variance_inflation_factor(X_sm.values, i)
  print(f'{X_sm.columns[i]}: {vif}')
```

```
--- NILAI VIF (Multikolinearitas) ---
const: 1.0
GDP per capita: 3.6933277861313774
Social support: 1.859808649291448
Healthy life expectancy: 3.7535904604112065
Perceptions of corruption: 1.1326459492740495
```

VIF (Variance Inflation Factor) mengukur seberapa kuat suatu variabel independen berkorelasi secara linear dengan variabel independen lainnya.
Karena nilai VIF nya cukup rendah untuk keseluruhan (<5), maka variabel-variabel tersebut **tidak terjadi multikolinearitas** dan cukup aman digunakan sebagai prediktor model prediksi.

AUTOKORELASI

Durbin Watson Test

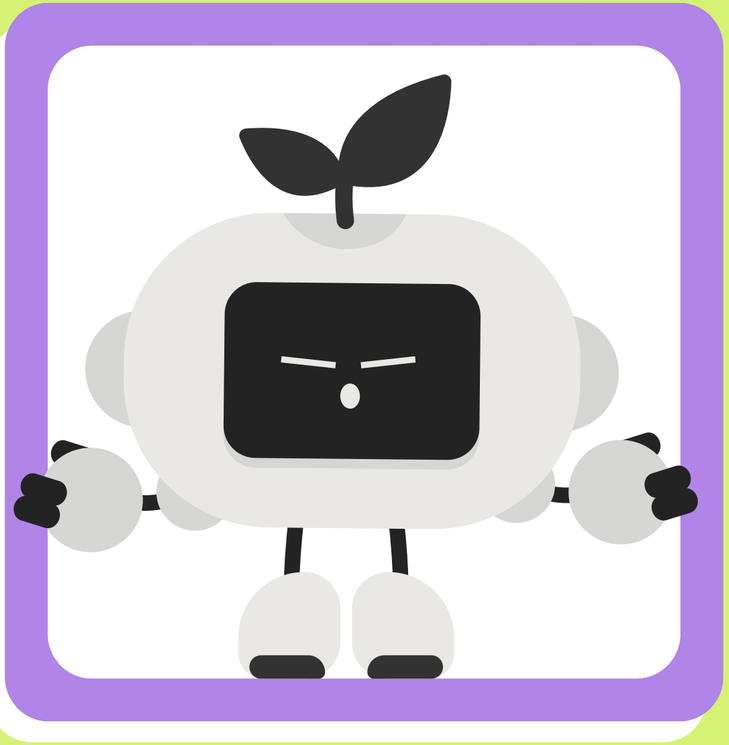
```
import statsmodels.api as sm
from statsmodels.stats.stattools import durbin_watson

dw = durbin_watson(residu)

print("Nilai Durbin-Watson:", dw)
```

```
Nilai Durbin-Watson: 1.2319914448781106
```

Durbin-Watson Test adalah uji statistik yang digunakan dalam analisis regresi untuk mengetahui apakah terdapat autokorelasi pada residual (kesalahan/error) model regresi.Sederhananya, uji ini memeriksa apakah kesalahan prediksi pada satu observasi memiliki hubungan dengan kesalahan prediksi pada observasi sebelumnya.Pada data ini, nilai Durbin Watson testnya adalah 1.23 yaitu berada di rentang 0-2 yang artinya **tidak terjadi autokorelasi antar nilai residu**.



KESIMPULAN

Berdasarkan hasil analisis regresi linear sederhana (SLR) dan regresi linear berganda (MLR) pada Happiness Index Dataset 2018, dapat disimpulkan bahwa variabel GDP per capita, Social Support, Healthy Life Expectancy, dan Perceptions of Corruption memiliki hubungan positif dengan Happiness Score. model regresi linear berganda (MLR) lebih baik dibandingkan regresi linear sederhana (SLR) karena mampu menjelaskan variasi Happiness Score lebih besar dan menghasilkan tingkat kesalahan prediksi yang lebih rendah. Hal ini menunjukkan bahwa tingkat kebahagiaan suatu negara tidak hanya berkaitan dengan faktor ekonomi, tetapi juga dipengaruhi oleh dukungan sosial, kesehatan, dan persepsi terhadap korupsi.

TERIMA KASIH!

Tetap semangat belajar matematika